

# tarantino\_profanity

June 5, 2020

## 1 Analiza vulgarnosti u Tarantinovim filmovima

Alati: Jupyter Notebook, Python (pandas, matplotlib i sl.), SQLite

```
[1]: import pandas as pd
df = pd.read_csv('profanity.csv')
df
```

```
[1]:
```

	movie	type	word	minutes_in
0	Reservoir Dogs	word	dick	0.40
1	Reservoir Dogs	word	dicks	0.43
2	Reservoir Dogs	word	fucked	0.55
3	Reservoir Dogs	word	fucking	0.61
4	Reservoir Dogs	word	bullshit	0.61
...	...	...	...	...
1889	Jackie Brown	word	motherfucker	141.93
1890	Jackie Brown	word	ass	142.43
1891	Jackie Brown	word	fucking	142.47
1892	Jackie Brown	word	goddamn	142.97
1893	Jackie Brown	death	NaN	143.13

[1894 rows x 4 columns]

```
[2]: data = {}
with open('profanity.csv') as file:
    for f in list(enumerate(file.readlines()[1:])):
        data[f[0]] = f[1:][0].rstrip().split(',')
```

```
[3]: rijeci = set(df.word)
```

```
[5]: filmovi = set(df.movie)
```

```
[6]: film = [('Django Unchained', 84, 2012, 165),
('Pulp Fiction', 89, 1994, 154),
('Inglorious Basterds', 83, 2009, 153),
('Kill Bill: Vol. 1', 81, 2003, 91),
('Jackie Brown', 75, 1997, 154),
('Reservoir Dogs', 83, 1992, 99),
```

```
('Kill Bill: Vol. 2', 80, 2004, 137)]
```

```
[7]: tip_vulgarnosti = set(df.type)
```

```
[8]: rijec = set(df.word)
rijec.add('death')
```

```
[9]: vulg = {}.fromkeys(rijec, [])
for entry in data:
    time = [[ entry, data[entry][3] ]]
    if data[entry][1] == 'word':
        vulg[data[entry][2]] = vulg[data[entry][2]] + time
    elif data[entry][1] == 'death':
        vulg['death'] = vulg['death'] + time
```

```
[10]: sorted_vulgs = []
only_sorted = []
base_words = ['shit', 'fuck', 'ass', 'damn', 'dick', 'cock', 'bitch', 'cunt', ]
for word in vulg.keys():
    for base in base_words:
        if type(word) == type('') and base in word:
            sorted_vulgs.append((base, word))
            only_sorted.append(word)
```

```
[11]: sorted_vulgs_db = sorted_vulgs + [(r,r) for r in rijec if r not in only_sorted]
sorted_vulgs_db[:5]
```

```
[11]: [('fuck', 'motherfucker'),
      ('shit', 'horeshit'),
      ('damn', 'damned'),
      ('fuck', 'fuck'),
      ('fuck', 'fuckhead')]
```

```
[12]: korijen = base_words + [r for r in rijec if r not in only_sorted]
```

```
[13]: korijen_db = []
for item in korijen:
    korijen_db.append((item,))
```

```
[14]: kategorije = ['fekalije', 'seks', 'psovke', 'pogrdnost', 'nacija', 'rasa', '
    ↪ 'smrt']
kategorije_db = []
for item in kategorije:
    kategorije_db.append((item,))
```

```
[15]: korijen_kat = [('shit', 'fekalije'),
('fuck', 'seks'),
('ass', 'seks'),
('damn', 'psovke'),
('dick', 'seks'),
('cock', 'seks'),
('bitch', 'pogrdnost'),
('cunt', 'seks'),
('slut', 'seks'),
('slope', 'rasa' ),
('jap', 'nacija'),
('pussy', 'seks'),
('death', 'smrt'),
('n-word ', 'rasa'),
('bastards', 'pogrdnost'),
('gooks', 'nacija'),
('hell', 'psovka'),
('jew (verb)', 'pogrdnost'),
('faggot', 'seks'),
('squaw', 'seks'),
('wetback', 'nacija'),
('merde', 'fekalije'),
('bastard', 'pogrdnost'),
('gook', 'nacija'),
('japs', 'nacija'),
('negro ', 'rasa')]
```

## 1.1 Upravljanje bazom podataka

```
[16]: import sqlite3
```

```
[17]: conn = sqlite3.connect('baza.db')
c = conn.cursor()
```

### 1.1.1 Tablica korijen

```
CREATE TABLE korijen(
    korijen_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT
    kategorija_fk INTEGER --- vraceno u korijen
    FOREIGN KEY (kategorija_fk)
        REFERENCES kategorija (kategorija_id)
);

INSERT INTO korijen(naziv) VALUES (?);
```

```
[18]: drop_table_korijen = '''
DROP TABLE korijen;
'''

c.execute(drop_table_korijen)

create_table_korijen='''
CREATE TABLE korijen(
    korijen_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT,
    kategorija_fk INTEGER,
    FOREIGN KEY (kategorija_fk)
        REFERENCES kategorija (kategorija_id)

);
'''

c.execute(create_table_korijen)

insert_into_korijen = '''
INSERT INTO korijen(naziv) VALUES (?);
'''

c.executemany(insert_into_korijen, korijen_db)
conn.commit()
```

### 1.1.2 Tablica kategorija

```
CREATE TABLE kategorija(
    kategorija_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT
);

INSERT INTO kategorija(naziv) VALUES (?);
```

```
[19]: drop_table_kat = '''
DROP TABLE kategorija;
'''

c.execute(drop_table_kat)

create_table_kat = '''
CREATE TABLE kategorija(
    kategorija_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT
);'''

c.execute(create_table_kat)
insert_into_kat = '''
INSERT INTO kategorija(naziv) VALUES (?);
'''
```

```
c.executemany(insert_into_kat, kategorije_db)
conn.commit()
```

### 1.1.3 Tablica film

```
CREATE TABLE film(
    film_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT NOT NULL,
    godina INTEGER,
    trajanje INTEGER, --- minute
    ocjena INTEGER, --- 0 <= ocjena <= 100
    CHECK (ocjena <= 100 AND
           ocjena >= 0)
);

INSERT INTO film (naziv, ocjena, godina) VALUES (?, ?, ?);
```

```
[20]: drop_table_film = '''DROP TABLE film;'''
c.execute(drop_table_film)

create_table_film = '''
CREATE TABLE film(
    film_id INTEGER PRIMARY KEY AUTOINCREMENT,
    naziv TEXT NOT NULL,
    godina INTEGER,
    trajanje INTEGER,
    ocjena INTEGER
    CHECK (ocjena <= 100 AND
           ocjena >= 0)
);
'''
c.execute(create_table_film)

insert_into_film = '''
INSERT INTO film (naziv, ocjena, godina, trajanje) VALUES (?, ?, ?, ?);
'''
c.executemany(insert_into_film, film)
conn.commit()
```

### 1.1.4 Tablica rijec

```
CREATE TABLE rijec (
    rijec_id INTEGER PRIMARY KEY, ---non-autoincrement!
    rijec TEXT NOT NULL,
    vrijeme REAL NOT NULL,
    film_fk INTEGER,
    FOREIGN KEY (film_fk)
        REFERENCES film (film_id)
```

```

    korijen_fk INTEGER,
    FOREIGN KEY (korijen_fk)
        REFERENCES korijen (korijen_id)
    kategorija_fk INTEGER    --- vraceno u korijen
    FOREIGN KEY (kategorija_fk)
        REFERENCES kategorija (kategorija_id)
);'''

```

```

'''sqlite
INSERT INTO rijec VALUES (?, ?, ?, NULL, NULL, NULL)

```

```

[21]: drop_table_rijec = '''
DROP TABLE rijec;
'''
c.execute(drop_table_rijec)

create_table_rijec = '''
CREATE TABLE rijec (
    rijec_id INTEGER PRIMARY KEY,
    rijec TEXT NOT NULL,
    vrijeme REAL NOT NULL,
    film_fk INTEGER,
    korijen_fk INTEGER,
    kategorija_fk INTEGER,    --- vraceno u korijen
    FOREIGN KEY (kategorija_fk)
        REFERENCES kategorija (kategorija_id)
);
'''
c.execute(create_table_rijec)

insert_into_rijec = '''
INSERT INTO rijec VALUES (?, ?, ?, NULL, NULL, NULL)
'''
c.executemany(insert_into_rijec, [(a, data[a][2], data[a][3]) for a in data])
conn.commit()

```

```

UPDATE rijec SET korijen_fk = (
    SELECT korijen_id FROM korijen
    WHERE naziv = ?
) WHERE rijec = ?

```

```

[22]: update_korijen_fk = '''
UPDATE rijec SET korijen_fk = (
    SELECT korijen_id FROM korijen
    WHERE naziv = ?
) WHERE rijec = ?

```

```
'''
c.executemany(update_korijen_fk, sorted_vulgs_db)
conn.commit()
```

```
UPDATE rijec SET film_fk = (
    SELECT film_id FROM film
    WHERE naziv = ?
) WHERE rijec_id = ?
```

```
[23]: update_film_fk = '''
UPDATE rijec SET film_fk = (
    SELECT film_id FROM film
    WHERE naziv = ?
) WHERE rijec_id = ?
'''
film_id = [(data[a][0], a) for a in data]
c.executemany(update_film_fk, film_id)
conn.commit()
```

```
UPDATE rijec SET kategorija_fk = (
    SELECT kategorija_id FROM kategorija
    WHERE naziv = ?
) WHERE korijen = (
    SELECT korijen_id FROM korijen
    WHERE naziv = ?
);
```

```
[24]: update_kategorija_fk = '''
UPDATE rijec SET kategorija_fk = (
    SELECT kategorija_id FROM kategorija
    WHERE naziv = ?
) WHERE korijen_fk = (
    SELECT korijen.korijen_id
    FROM korijen
    WHERE naziv = ?
);
'''
c.executemany(update_kategorija_fk, [(a[1], a[0]) for a in korijen_kat])
conn.commit()
```

### 1.1.5 Upiti

Ispitivanje postoji li vezanost između količine psovki i ocjene.

```
[25]: import matplotlib as mpl
import matplotlib.pyplot as plt
```

[27]: *#Ispitivanje postoji li veza između gustoće psovki i ocjene.*

```
avg_per_film = '''
SELECT CAST (COUNT() as float)/film.trajanje, film.ocjena
FROM rijec, film
WHERE film_id = film_fk
GROUP BY film_fk
'''
rez = c.execute(avg_per_film).fetchall()

podatci_avg = sorted(rez)
list(zip(*podatci_avg))

fig = plt.figure()
ax1 = fig.add_subplot(111)
ax1.set_ylabel('ocjena')
ax1.set_xlabel('broj psovki po minuti')

plt.grid(True)
plt.scatter(*zip(*podatci_avg))
plt.plot(*zip(*podatci_avg))
plt.savefig('rad/slike/psovke_po_minuti.pdf')
plt.show()
```

[28]: `from collections import Counter`



```
[29]: def psovka_dio_filma(db_cursor, ime_filma, detail = 10, vulg = 'word'):
    vulg = '!' if vulg == 'word' else '='
    upit = '''
    SELECT CAST (rijec.vrijeme/film.trajanje*{0} as INTEGER) as psovka_pc
    FROM film, rijec
    WHERE rijec.film_fk = film_id
        AND rijec.rijec {2}= ''
        AND film.naziv = '{1}'
    '''.format(detail, ime_filma, vulg)
    data = db_cursor.execute(upit).fetchall()

    data = list(x[0] for x in data)
    data = dict(Counter(data))
    fig, ax = plt.subplots()
    ax.set_title(ime_filma)
    ax.set_ylabel('Vrijeme')
    ax.set_xlabel('Broj psovki')

    fig.tight_layout()
    ax.grid(True)
    ax.bar(data.keys(), data.values())
    plt.savefig("rad/slike/" + ime_filma + "_" + vulg + ".pdf")
    plt.show()
```

```
[30]: psovka_dio_filma(c, 'Kill Bill: Vol. 2', detail = 20, vulg='word')
```

```
[31]: for film in filmovi:  
      psovka_dio_filma(c, film, detail = 30)
```







```
[32]: psovki_po_godini = '''
SELECT CAST (COUNT() as float)/film.trajanje, film.godina
FROM rijec, film
WHERE film_id = film_fk
GROUP BY film_fk
'''

rez = c.execute(psovki_po_godini).fetchall()
print(rez)
```

```
[(1.8727272727272728, 2012), (3.090909090909091, 1994), (0.6928104575163399,
2009), (1.3186813186813187, 2003), (2.4155844155844157, 1997),
(4.353535353535354, 1992), (0.583941605839416, 2004)]
```

```
[33]: fig = plt.figure()
ax1 = fig.add_subplot(111)
ax1.set_ylabel('broj psovki po minuti')
ax1.set_xlabel('godina')
fig.tight_layout()
plt.grid(True)
plt.xticks([1990, 1995, 2000, 2005, 2010, 2015])
plt.bar([int(a[1]) for a in rez], [a[0] for a in rez], align='edge', width=0.8,
        color='orange')
#plt.plot(*zip(*rez))
plt.savefig('rad/slike/psovke_godine.pdf')
plt.show()
```

```

[34]: detail = 30
fig, ax = plt.subplots()
ax.set_title('Distribucija psovki')
vulg = '!'
ax.set_xlabel('Vrijeme')
ax.set_ylabel('Broj psovki')
suma = []
for film in filmovi:
    upit = '''
    SELECT CAST (rijec.vrijeme/film.trajanje*{0} as INTEGER) as psovka_pc
    FROM film, rijec
    WHERE rijec.film_fk = film_id
      AND rijec.rijec {2}= ''
      AND film.naziv = '{1}'
    '''.format(detail, film, vulg)

    data = c.execute(upit).fetchall()
    data = list(x[0] for x in data)

    data = dict(Counter(data))
    suma.append(data)
    #print(suma)

    ax.plot(list(data.keys()), list(data.values()), label=film)
import functools, operator
result = dict(functools.reduce(operator.add, map(Counter, suma)))
ax.plot(list(result.keys()), list(result.values()), label="zbroj svih")
fig.tight_layout()
ax.grid(True)

plt.legend(loc="upper right")

plt.savefig("rad/slike/filmovi_distribucija_psovki.pdf")
plt.show()

```

Najcesce psovke:

```
[35]: najcesce_psovke = '''
      SELECT kategorija.naziv, COUNT(rijec.kategorija_fk) ---, korijen.naziv
      FROM kategorija, rijec
      WHERE rijec.kategorija_fk = kategorija_id
      GROUP BY rijec.kategorija_fk;
      '''
      rez = c.execute(najcesce_psovke).fetchall()
```

```
[36]: fig, ax = plt.subplots()
      ax.set_title('Broj psovki po kategorijama')
      ax.set_xlabel('Kategorija psovki')
      ax.set_ylabel('Broj psovki')

      print(rez)

      fig.tight_layout()
      ax.grid(False)
      ax.bar(*zip(*rez), color='ForestGreen')
      ax.grid(True)
      plt.savefig("rad/slike/kategorije_total.pdf")
      plt.show()
```



```
[('fekalije', 253), ('seks', 974), ('psovke', 154), ('pogrdnost', 85),  
('nacija', 8), ('rasa', 185)]
```

```
[37]: fig, ax = plt.subplots()  
ax.set_title('Broj psovki po kategorijama po filmu')  
ax.set_ylabel('Broj psovki')  
ax.set_xlabel('Kategorija psovki')  
for film in filmovi:  
    najcesce_psovke = '''  
        SELECT kategorija.naziv, COUNT(rijec.kategorija_fk), film.naziv ---,   
        ↪ korijen.naziv  
        FROM kategorija, rijec, film  
        WHERE rijec.kategorija_fk = kategorija_id  
        AND film.film_id = rijec.film_fk  
        AND rijec.film_fk = (SELECT film.film_id FROM film WHERE film.naziv =   
        ↪ "{}" )  
        GROUP BY rijec.kategorija_fk;  
    '''.format(film)  
    rez = c.execute(najcesce_psovke).fetchall()  
  
    kategorije = list(list(a) for a in zip(*rez))  
    fig.tight_layout()  
    ax.grid(False)  
    ax.bar(kategorije[0], kategorije[1], label=kategorije[2][1])
```

```
plt.legend(loc = "best")
plt.savefig("rad/slike/kategorije_total_po_filmovima.pdf")
plt.show()
```

[ ]:

[ ]: